

TRƯỜNG ĐẠI HỌC CẦN THƠ
KHOA CÔNG NGHỆ THÔNG TIN & TRUYỀN THÔNG



BÁO CÁO THỰC TẬP THỰC TẾ - CT473
NGÀNH KHOA HỌC MÁY TÍNH

Đề tài

**XÂY DỰNG ỨNG DỤNG SỐ HÓA VĂN BẢN HÀNH
CHÍNH BẰNG CÔNG CỤ OCR**

Giáo viên hướng dẫn:
Th.s Trần Việt Châu

Cán bộ hướng dẫn:
Phan Thanh Giảng

Cần Thơ, 07/2023

LỜI CẢM ƠN

Thực tập thực tế ngành Khoa học máy tính với Đề tài xây dựng ứng dụng số hóa văn bản hành chính bằng công cụ OCR là kết quả của quá trình cố gắng tôi và được sự giúp đỡ tận tình của của các cán bộ tại trung tâm công nghệ phần mềm VNPT Vĩnh Long. Qua đây, em xin gửi lời cảm ơn chân thành đến những người đã giúp đỡ em trong suốt thời gian thực tập – làm việc vừa qua.

Xin cảm ơn trường CNTT-TT và Khoa Khoa học máy tính đã tạo điều kiện cho em học tập, tích lũy kinh nghiệm trong suốt quá trình vừa qua. Các kiến thức đã được học tập đã giúp đỡ em rất nhiều trong quá trình thực tập tại trung tâm công nghệ phần mềm VNPT Vĩnh Long.

Em xin trân trọng gửi đến thầy Th.s Trần Việt Châu - Người đã trực tiếp tận tình hướng dẫn cũng như cung cấp tài liệu, thông tin khoa học cần thiết, đồng thời là người thăm hỏi trong quá trình thực tập thực tế lời cảm ơn chân thành và sâu sắc nhất.

Xin chân thành cảm ơn trung tâm công nghệ phần mềm VNPT Vĩnh Long đã tạo điều kiện để em được thực tập thực tế để hoàn thành học phần thực tập thực tế song đó giúp em tích lũy nhiều được kinh nghiệm thực tế trong quá trình thực tập.

Xin cảm ơn PGĐ. Thiện của trung tâm phần mềm VNPT Vĩnh Long đã hướng dẫn chỉ bảo trong suốt quá trình thực tập cho em có được nhiều bài học khi làm việc ở cơ quan.

Xin cảm ơn anh Phan Thanh Giảng các người anh, những cán bộ trực tiếp hướng dẫn cũng như hỗ trợ trong suốt quá trình thực tập thực tế.

Cuối cùng, em xin cảm ơn gia đình, người thân, bạn bè đã luôn bên cạnh, ủng hộ, động viên. Em xin chân thành cảm ơn!

PHIẾU ĐÁNH GIÁ BÁO CÁO KẾT QUẢ THỰC TẬP
HỌC KỲ 3 – 2022-2023
(Dùng cho giáo viên chấm báo cáo thực tập)
NGÀNH KHOA HỌC MÁY TÍNH

Họ và tên cán bộ chấm báo cáo:.....

Họ tên sinh viên thực tập:.....Mã số SV:.....

Nội dung đánh giá	Điểm tối đa	Điểm chấm
I. Hình thức trình bày	1.0	
I.1 Đúng format của khoa (Trang bìa, trang lời cảm ơn, trang đánh giá thực tập của khoa, trang mục lục và các nội dung báo cáo). Sử dụng đúng mã và font tiếng Việt (Unicode Times New Roman, Size 13)	0.5	
I.2 Trình bày mạch lạc, súc tích, không có lỗi chính tả	0.5	
II. Phiếu theo dõi	6.0	
II.1 Có lịch làm việc đầy đủ cho 8 tuần	1.0	
II.3 Hoàn thành tốt kế hoạch công tác ghi trong lịch làm việc. Cách tính điểm = (Điểm cộng của cán bộ hướng dẫn/100) x 5	5.0	
III. Nội dung thực tập (quyển báo cáo)	3.0	
III.1 Có được sự hiểu biết tốt về cơ quan nơi thực tập	0.5	
III.2 Phương pháp thực hiện phù hợp với nội dung công việc được giao	0.5	
III.3 Kết quả củng cố lý thuyết	0.5	
III.4 Kết quả rèn luyện kỹ năng thực hành	0.5	
III.5 Kinh nghiệm thực tiễn thu nhận được	0.5	
III.6 Kết quả công việc có đóng góp cho cơ quan nơi thực tập	0.5	
TỔNG CỘNG	10	
Điểm trừ		
Điểm còn lại		

....., ngày....tháng....năm.....
GIÁO VIÊN CHẤM BÁO CÁO
(ký tên)

MỤC LỤC

PHẦN 1	6
TỔNG QUAN VỀ VNPT VĨNH LONG	6
1.1 LỊCH SỬ HÌNH THÀNH VÀ PHÁT TRIỂN CỦA TẬP ĐOÀN BƯU CHÍNH VIỄN THÔNG VIỆT NAM	6
1.2 LỊCH SỬ HÌNH THÀNH VÀ PHÁT TRIỂN CỦA VNPT VĨNH LONG	6
1.2.1 Quá trình hình thành và phát triển	6
1.2.2 Chức năng và nhiệm vụ của VNPT Vĩnh Long	7
1.2.3 Một số sản phẩm và dịch vụ chính do VNPT Vĩnh Long cung cấp	9
PHẦN 2	10
CƠ CẤU TỔ CHỨC CỦA VNPT VĨNH LONG	10
2.1 Giám đốc	10
2.2 Phó giám đốc kinh doanh	10
2.3 Phó giám đốc kỹ thuật	10
2.4 Các phòng, ban chức năng tham mưu	10
2.5 Các đơn vị kinh tế trực thuộc, hạch toán phụ thuộc	10
2.6 Mô hình tổ chức hoạt động VNPT Vĩnh Long	11
PHẦN 3	12
PHƯƠNG PHÁP THỰC HIỆN ĐỀ TÀI	12
3.1 Giới thiệu tổng quát về OCR	12
3.1.1 Khái niệm	12
3.1.2 Cách thức hoạt động	12
Thu nhận hình ảnh	12
Tiền xử lý	12
Nhận dạng văn bản	12
Hậu xử lý	13
3.1.3 Một số thư viện OCR thông dụng	13
3.2 Các bước thực hiện	14
3.2.1 Xử lý dữ liệu file pdf đầu vào	14
3.2.2 Thiết kế API cho ứng dụng	17
Thiết kế API upload file pdf văn bản hành chính và kiểm tra kết quả	18
Thiết kế API hiển thị tất cả thông tin file pdf và kiểm tra kết quả	18

Thiết kế API xóa dữ liệu đã trích xuất và kiểm tra kết quả	19
Thiết kế API chỉnh sửa dữ liệu đã trích xuất và kiểm tra kết quả	19
3.2.2 Thiết kế giao diện cho ứng dụng.....	20
Phần 4.....	22
KẾT QUẢ ĐẠT ĐƯỢC QUA ĐỢT THỰC TẬP	22
4.1 Những kết quả đạt được.....	22
4.2 Bài học kinh nghiệm và những điều đạt được sau 8 tuần thực tập	22
4.3 Hướng phát triển	22

MỤC LỤC HÌNH ẢNH

Hình 1: Kết quả kiểm tra hoạt động của API POST	18
Hình 2: Kết quả kiểm tra hoạt động của API GET	18
Hình 3: Kết quả kiểm tra hoạt động của API DELETE.....	19
Hình 4: Dữ liệu trước khi chỉnh sửa	19
Hình 5: Kết quả kiểm tra hoạt động của API PUT	19
Hình 6: Trang chủ	20
Hình 7: Trang cập nhật thông tin	20
Hình 8: Trang danh sách các văn bản	21
Hình 9: Kiểm tra hoạt động trích xuất thông tin.....	21

PHẦN 1

TỔNG QUAN VỀ VNPT VĨNH LONG

1.1 LỊCH SỬ HÌNH THÀNH VÀ PHÁT TRIỂN CỦA TẬP ĐOÀN BƯU CHÍNH VIỄN THÔNG VIỆT NAM

Tên đầy đủ: *Tập đoàn Bưu chính Viễn thông Việt nam*

Tên giao dịch quốc tế: *Vietnam Posts and Telecommunications Group*

Tên viết tắt: VNPT

Trụ sở: *57 Huỳnh Thúc Kháng, Q.Đống Đa, Tp. Hà Nội*

Website: www.vnpt.com.vn

E-mail: vnpt_website@vnpt.com.vn

VNPT là nhà cung cấp dịch vụ đầu tiên đặt nền móng cho sự phát triển của ngành Bưu chính, Viễn thông Việt Nam, là Tập đoàn có vai trò chủ chốt trong việc đưa Việt Nam trở thành 1 trong 10 quốc gia có tốc độ phát triển Bưu chính Viễn thông nhanh nhất toàn cầu. Với hạ tầng công nghệ viễn thông tiên tiến, mạng lưới dịch vụ phủ sóng toàn bộ 63 tỉnh thành trên cả nước.

Lĩnh vực kinh doanh :

Dịch vụ và sản phẩm viễn thông, công nghệ thông tin;

Dịch vụ và sản phẩm truyền thông;

Khảo sát, tư vấn, thiết kế, xây dựng, lắp đặt, bảo dưỡng các công trình viễn thông, công nghệ thông tin và truyền thông;

Sản xuất, kinh doanh xuất nhập khẩu, cung ứng vật tư, thiết bị viễn thông, công nghệ thông tin và truyền thông;

Dịch vụ tài chính, tín dụng, ngân hàng;

Dịch vụ quảng cáo, tổ chức sự kiện;

Kinh doanh bất động sản, cho thuê văn phòng;

1.2 LỊCH SỬ HÌNH THÀNH VÀ PHÁT TRIỂN CỦA VNPT VĨNH LONG

1.2.1 Quá trình hình thành và phát triển

VNPT Vĩnh Long là đơn vị thành viên trực thuộc Tập đoàn Bưu chính Viễn thông Việt Nam, được thành lập từ ngày 01/01/2008 trên cơ sở tổ chức lại các đơn vị kinh doanh dịch vụ viễn thông công nghệ thông tin (VT - CNTT) và các đơn vị trực thuộc khác của Bưu điện Vĩnh Long sau khi thực hiện phương án chia tách Bưu chính Viễn thông trên địa bàn tỉnh. Tổ chức và hoạt động của Viễn thông Vĩnh Long được

quy định cụ thể theo điều lệ tổ chức và hoạt động được phê chuẩn tại quyết định số 698/QĐ-TCCB/HĐQT ngày 06/12/2007 do Hội đồng quản trị Tập đoàn Bưu chính Viễn thông Việt Nam ban hành.

Tên gọi đầy đủ: Viễn thông Vĩnh Long

Tên giao dịch: VNPT Vĩnh Long

Tên giao dịch quốc tế là: VINH LONG Telecommunications

Trụ sở chính: số 03 Trưng Nữ Vương, phường 1, thành phố Vĩnh Long, tỉnh Vĩnh Long.

Điện thoại liên hệ: (84070) 3829999

Fax: (84070) 3831666

Website: <http://vinhlong.vnpt.vn>

1.2.2 Chức năng và nhiệm vụ của VNPT Vĩnh Long

**** Chức năng***

VNPT Vĩnh Long là đơn vị kinh tế trực thuộc, hạch toán phụ thuộc Tập đoàn Bưu chính Viễn thông Việt Nam; có con dấu riêng theo tên gọi, được đăng ký kinh doanh, được mở tài khoản tại ngân hàng; có chức năng hoạt động sản xuất kinh doanh và phục vụ chuyên ngành VT - CNTT như sau:

Tổ chức xây dựng, quản lý, vận hành, lắp đặt, khai thác, bảo dưỡng, sửa chữa mạng viễn thông trên địa bàn tỉnh. Tổ chức, quản lý, kinh doanh và cung cấp các dịch vụ VT – CNTT.

Sản xuất, kinh doanh, cung ứng, đại lý vật tư, thiết bị VT - CNTT theo yêu cầu sản xuất kinh doanh của đơn vị và nhu cầu của khách hàng, khảo sát, tư vấn, thiết kế, lắp đặt, bảo dưỡng các công trình VT - CNTT; Kinh doanh dịch vụ quảng cáo, dịch vụ truyền thông.

Kinh doanh bất động sản, cho thuê văn phòng; Tổ chức phục vụ thông tin đột xuất theo yêu cầu của cấp ủy Đảng, Chính quyền địa phương và cấp trên; Kinh doanh các ngành nghề khác khi được Tập đoàn cho phép.

**** Nhiệm vụ***

Sử dụng có hiệu quả nguồn lực của Nhà Nước được Tập đoàn giao nhằm phát triển kinh doanh và phục vụ, bảo toàn, phát triển vốn và các nguồn lực khác được giao; Có nghĩa vụ trả các khoản nợ mà đơn vị trực tiếp vay theo quy định của pháp luật

Đăng ký kinh doanh và kinh doanh đúng danh mục ngành nghề đã đăng ký, chịu trách nhiệm trước Tập đoàn về kết quả hoạt động, chịu trách nhiệm trước khách hàng và luật pháp về sản phẩm, dịch vụ do đơn vị cung cấp. Trình Tập đoàn phương án giá cước liên quan tới các dịch vụ do đơn vị kinh doanh

Phối hợp, tạo điều kiện thuận lợi mọi mặt cho các đơn vị khác thuộc Tập đoàn để đạt các mục tiêu kế hoạch chung về kinh doanh và phục vụ trong toàn Tập đoàn

Đảm bảo thông tin liên lạc phục vụ các cơ quan Đảng, Nhà Nước, phục vụ quốc phòng an ninh, các yêu cầu thông tin liên lạc khẩn cấp, đảm bảo các dịch vụ viễn thông cơ bản trên địa bàn được giao quản lý với thẩm quyền theo quy định; Chịu sự chỉ đạo và điều hành mạng thông tin viễn thông thống nhất trên toàn lãnh thổ của Tập đoàn Bưu chính viễn thông Việt nam

Xây dựng, quy hoạch và phát triển đơn vị trên cơ sở chiến lược, quy hoạch của Tập đoàn và phạm vi chức năng, nhiệm vụ của đơn vị trên địa bàn và trong lĩnh vực viễn thông

Xây dựng kế hoạch dài hạn, ngắn hạn phù hợp với mục tiêu, phương hướng và các chỉ tiêu kế hoạch phát triển toàn Tập đoàn

Chấp hành các quy định của Nhà nước, của Tập đoàn về điều lệ, thể lệ thủ tục nghiệp vụ, về các quy trình, quy phạm, tiêu chuẩn kỹ thuật, về giá, cước và các chính sách về giá, cước các sản phẩm dịch vụ viễn thông

Đổi mới, hiện đại hóa thiết bị mạng lưới, công nghệ và phương thức quản lý trong quá trình xây dựng và phát triển đơn vị trên cơ sở phương án đã được Tập đoàn phê duyệt;

Thực hiện đầy đủ nghĩa vụ và quyền lợi đối với người lao động theo quy định của Bộ luật lao động, đảm bảo cho người lao động tham gia quản lý đơn vị

Thực hiện nghĩa vụ theo quy định của Nhà nước về bảo vệ tài nguyên, môi trường, quốc phòng và an ninh quốc gia, thực hiện chế độ báo cáo thống kê, báo cáo định kỳ, bất thường, chế độ kiểm toán theo quy định của Nhà nước và của Tập đoàn, chịu trách nhiệm về tính xác thực của báo cáo

Thực hiện nghiêm chỉnh luật kế toán và các chế độ tài chính kế toán thống kê hiện hành đối với doanh nghiệp nhà nước, chịu sự quản lý, kiểm tra, kiểm soát của Tập đoàn, tuân thủ các quy định của các cơ quan Nhà nước có thẩm quyền theo quy định của pháp luật

Có trách nhiệm thực hiện đầy đủ kịp thời nghĩa vụ thuế, các khoản nộp ngân sách nhà nước theo quy định của pháp luật, các khoản phải nộp về Tập đoàn theo quy

định tại quy chế tài chính của Tập đoàn Bưu chính viễn thông Việt Nam

1.2.3 Một số sản phẩm và dịch vụ chính do VNPT Vĩnh Long cung cấp

VNPT Vĩnh Long là đơn vị chủ lực cung cấp các dịch vụ viễn thông trên địa bàn của tỉnh gồm các dịch vụ sau:

Điện thoại cố định, Gphone /Fax.VoIP (171, 1717).

Điện thoại di động (Trả trước, trả sau, thuê bao ezcom)

Các dịch vụ 3G của Vinaphone

Bán thẻ nạp tiền cho ĐTDĐ, game các loại,...

Internet (Mega Vnn, Fiber Vnn/ADSL, FTTH).

Dịch vụ truyền hình thông minh My TV.

Các dịch vụ về CNTT.

Truyền số liệu (Kênh thuê riêng, leastline, Mega Wan, truyền hình hội nghị). Cho thuê cơ sở hạ tầng để lắp thiết bị viễn thông (phòng máy, cột anten,...). Các dịch vụ gia tăng trên nền mạng thế hệ sau NGN (1900, 1800, 1719, ... Hộp thư thông tin (1080, 1088. 801xxx, 8xxx) các dịch vụ nội dung.

PHẦN 2

CƠ CẤU TỔ CHỨC CỦA VNPT VĨNH LONG

Mô hình tổ chức của VNPT Vĩnh Long gồm: bộ máy quản lý, các đơn vị kinh tế trực thuộc, hạch toán phụ thuộc VNPT Vĩnh Long. Bộ máy quản lý của VNPT Vĩnh Long hoạt động theo mô hình “trực tuyến - chức năng - tham mưu” mệnh lệnh điều hành sản xuất và hoạt động của VNPT Vĩnh Long trực tuyến từ giám đốc VNPT đến các đơn vị trực thuộc gồm Ban giám đốc các Trung tâm trực thuộc và các phòng, ban chức năng. Ban giám đốc VNPT Vĩnh Long gồm: 01 Giám đốc và 02 Phó giám đốc

2.1 Giám đốc

Do Tổng giám đốc Tập đoàn bổ nhiệm, miễn nhiệm, khen thưởng, kỷ luật sau khi được Hội đồng quản trị Tập đoàn phê duyệt; Là người đại diện theo pháp luật của Đơn vị; chịu trách nhiệm trước Tập đoàn và trước pháp luật về việc quản lý, điều hành hoạt động của đơn vị trong phạm vi quyền hạn và nghĩa vụ được quy định trong điều lệ và các văn bản quy định khác của Tập đoàn, là người có quyền quản lý và điều hành cao nhất của Đơn vị về toàn bộ các hoạt động sản xuất kinh doanh; trực tiếp quản lý các lĩnh vực kế hoạch sản xuất, tài chính, lao động, tiền lương, các chính sách xã hội khác.

2.2 Phó giám đốc kinh doanh

Do Tổng giám đốc Tập đoàn bổ nhiệm, miễn nhiệm, thay thế, khen thưởng, kỷ luật theo đề nghị của giám đốc Đơn vị; được giám đốc phân công giúp giám đốc điều hành sản xuất kinh doanh trên toàn tỉnh đảm bảo chất lượng dịch vụ, năng suất và hiệu quả kinh doanh.

2.3 Phó giám đốc kỹ thuật

Do Tổng giám đốc Tập đoàn bổ nhiệm, miễn nhiệm, thay thế, khen thưởng, kỷ luật theo đề nghị của giám đốc Đơn vị; được giám đốc giao nhiệm vụ trực tiếp quản lý, điều hành mạng viễn thông, quản lý công tác đầu tư xây dựng cơ bản, đảm bảo ổn định về chất lượng mạng lưới, chất lượng thông tin, năng suất và hiệu quả kinh doanh


2.4 Các phòng, ban chức năng tham mưu

Gồm các phòng, ban chuyên môn giúp giám đốc trong việc quản lý và điều hành công việc chuyên môn theo từng lĩnh vực, chịu trách nhiệm trước giám đốc về nhiệm vụ và nội dung công việc được giao bao gồm: Phòng Hành chính Tổng hợp, Phòng Tổ chức lao động, Phòng Tài chính - Kế toán, Phòng Kế hoạch - Kinh doanh, Phòng Đầu tư - Xây dựng cơ bản, Phòng Mạng và Dịch vụ, Trung tâm Điều hành Thông tin, Trung tâm Công nghệ Thông tin.

2.5 Các đơn vị kinh tế trực thuộc, hạch toán phụ thuộc

Các đơn vị kinh tế trực thuộc VNPT Vĩnh Long có con dấu riêng theo tên gọi, được đăng ký kinh doanh, được mở tài khoản tại ngân hàng, hoạt động theo điều lệ tổ chức và phân cấp quản lý của Giám Đốc VNPT Vĩnh Long quy định gồm các đơn vị: Trung tâm Kinh doanh, Trung tâm Viễn thông: Vĩnh Long, Bình Minh, Bình Tân, Long Hồ, Mang Thít, Tam Bình, Trà Ôn, Vũng Liêm.

2.6 Mô hình tổ chức hoạt động VNPT Vĩnh Long



PHẦN 3

PHƯƠNG PHÁP THỰC HIỆN ĐỀ TÀI

3.1 Giới thiệu tổng quát về OCR

3.1.1 Khái niệm

OCR là thuật ngữ được viết tắt bởi cụm từ **Optical Character Recognition** (dịch là: nhận dạng ký tự quang học). Đây là ứng dụng công nghệ chuyên dùng để đọc text ở file ảnh. Được biết đến là một công cụ scan kỹ thuật số chuyên nhận dạng các ký tự, chữ viết tay, hay chữ đánh máy, công nghệ này chuyên dùng để truyền tải, nhập liệu dữ liệu. Đặc biệt, ở OCR có khả năng kỹ thuật số nhiều dưới nhiều dạng tài liệu khác nhau: hóa đơn, hộ chiếu, danh thiếp, tài liệu...

3.1.2 Cách thức hoạt động

Công cụ OCR hoặc phần mềm OCR hoạt động theo các bước sau:

Thu nhận hình ảnh

Một máy quét sẽ đọc tài liệu và chuyển đổi chúng thành dữ liệu nhị phân. Phần mềm OCR phân tích hình ảnh đã quét và phân loại vùng sáng làm nền và vùng tối làm văn bản.

Tiền xử lý

Trước tiên, phần mềm OCR sẽ làm sạch hình ảnh và loại bỏ các lỗi để chuẩn bị cho bước đọc. Sau đây là một số kỹ thuật làm sạch của phần mềm OCR:

- Chỉnh thẳng hoặc nghiêng nhẹ tài liệu đã quét để khắc phục lỗi về căn chỉnh trong quá trình quét.
- Khử nhiễu đốm hoặc loại bỏ mọi đốm ảnh kỹ thuật số hay làm mịn các viền của hình ảnh văn bản.
- Làm sạch đường viền khung và đường thẳng trong hình ảnh.
- Nhận dạng chữ viết cho công nghệ OCR đa ngôn ngữ.

Nhận dạng văn bản

Hai loại thuật toán OCR hoặc quy trình phần mềm chính mà phần mềm OCR sử dụng để nhận dạng văn bản được gọi là so khớp mẫu và trích xuất đặc điểm.

So khớp mẫu

Cách thức hoạt động của so khớp mẫu là tách biệt một hình ảnh ký tự, được gọi là hình dạng chữ và so sánh với một hình dạng chữ tương tự được lưu trữ. Tính năng nhận dạng mẫu chỉ hoạt động hiệu quả khi hình dạng chữ được lưu trữ có phong chữ và tỷ lệ tương tự với hình dạng chữ đầu vào. Phương thức này hoạt động tốt đối với hình ảnh quét từ tài liệu được đánh máy bằng phong chữ đã biết.

Trích xuất đặc điểm

Trích xuất đặc điểm sẽ chia nhỏ hoặc phân tách hình dạng chữ thành các đặc điểm như nét thẳng, nét vòng khép kín, hướng nét và giao điểm nét. Sau đó, hệ thống sử dụng các đặc điểm này để tìm kết quả phù hợp nhất hoặc kết quả gần đúng nhất trong số các hình dạng chữ khác nhau được lưu trữ.

Hậu xử lý

Sau khi phân tích, hệ thống sẽ chuyển đổi dữ liệu văn bản được trích xuất thành tệp trên máy tính. Một số hệ thống OCR có thể tạo các tệp PDF có chú thích bao gồm cả phiên bản trước và sau của tài liệu được quét.

3.1.3 Một số thư viện OCR thông dụng

Pytesseract OCR

- PytesseractOCR là một thư viện OCR mã nguồn mở được phát triển dựa trên Tesseract, một công cụ OCR mạnh mẽ.
- Nó hỗ trợ nhiều ngôn ngữ và có khả năng nhận diện văn bản từ hình ảnh và file PDF. PytesseractOCR được viết bằng Python và cung cấp API dễ sử dụng, giúp tích hợp dễ dàng vào các ứng dụng Python.
- Tuy nhiên, PytesseractOCR cần sự chuẩn bị và xử lý ảnh trước để đạt được kết quả tốt.

EasyOCR

- EasyOCR là một thư viện OCR mã nguồn mở được phát triển bởi JaidedAI.
- Nó cung cấp khả năng nhận diện văn bản từ hình ảnh và hỗ trợ hơn 80 ngôn ngữ.
- EasyOCR được viết bằng Python và có thể tích hợp vào các ứng dụng Python dễ dàng.
- Điểm mạnh của EasyOCR là khả năng nhận diện đa ngôn ngữ và khả năng làm việc trực tiếp trên ảnh gốc mà không yêu cầu xử lý ảnh trước.

Google Cloud Vision OCR

- Google Cloud Vision OCR là một dịch vụ nhận diện ký tự trên đám mây được cung cấp bởi Google Cloud.
- Nó cung cấp khả năng nhận diện và phân tích văn bản từ hình ảnh, bao gồm cả văn bản in và viết tay.
- Google Cloud Vision OCR có khả năng xử lý hàng loạt hình ảnh và hỗ trợ nhiều ngôn ngữ.

Microsoft Azure OCR

- Microsoft Azure OCR là một dịch vụ nhận diện ký tự trên đám mây do Microsoft Azure cung cấp.
- Nó cho phép bạn nhận diện văn bản từ hình ảnh và cung cấp các khả năng như xác định ngôn ngữ và phân loại văn bản.
- Microsoft Azure OCR hỗ trợ nhiều ngôn ngữ và cung cấp các API để sử dụng cho tích hợp vào ứng dụng.

Adobe Acrobat OCR

- Adobe Acrobat OCR là một phần của Adobe Acrobat, một phần mềm đọc và xử lý file PDF phổ biến.
- Nó cung cấp tính năng nhận diện và trích xuất văn bản từ file PDF hoặc hình ảnh được nhập vào.
- Adobe Acrobat OCR hỗ trợ nhiều ngôn ngữ và có khả năng xử lý các tệp PDF lớn với độ chính xác cao.

Kết luận: các thư viện OCR trên đây chỉ là một số ví dụ phổ biến. Trên thực tế, còn nhiều công cụ OCR khác nhau với các tính năng và ưu điểm riêng. Trong đề tài này sẽ sử dụng thư viện **Pytesseract OCR** để thực hiện.

3.2 Các bước thực hiện

3.2.1 Xử lý dữ liệu file pdf đầu vào

Xử lý file pdf văn bản hành chính

Bước 1: Nhận một file pdf được upload từ client (bước này sẽ được xử lý ở phần thiết kế API để upload file pdf và tiến hành truy xuất dữ liệu).

Bước 2: Tiến hành đọc file pdf và chuyển file pdf thành hình ảnh thông qua phương thức `convert_from_path` được cung cấp từ thư viện **Pytesseract OCR**. Mục đích của việc chuyển này vì mô hình không thể đọc được trực tiếp file pdf mà chỉ đọc được hình ảnh.

Bước 3: Tiếp theo sử dụng phương thức `image_to_string` cũng được cung cấp từ thư viện **Pytesseract OCR** để đọc file ảnh đã được chuyển từ bước trên chuyển thành các đoạn text, khi đọc xong thì các đoạn text này sẽ được đọc riêng lẻ theo từng dòng trong văn bản thế nên cần phải kết nối các dòng này lại với nhau thành một đoạn thống nhất để dễ dàng xử lý sau này.

Sau khi xử lý xong các bước trên sẽ tiến hành đến phần trích xuất các thông tin cần thiết từ đoạn text đã được xử lý.

Các bước trích xuất thông tin dữ liệu từ đoạn text đã được xử lý ở trên

Các thông tin cần trích xuất như: loại văn bản, nội dung văn bản, quốc hiệu tiêu ngữ, số văn bản, ngày ban hành. Sau đây là các bước trích xuất các đặc trưng trên.

- Trích xuất quốc hiệu tiêu ngữ:

Bước 1: xây dựng 2 biểu thức chính quy để trích xuất 2 cụm “Cộng hòa xã hội chủ nghĩa Việt Nam” và “Độc lập – Tự do – Hạnh phúc”.

✓ **Biểu thức chính quy 1:**

"(?i)\bCỘNG\s?H[ÒO][ÃA]\s?X[ÃA]\s?HỘI\s?CHỦ\s?NGHĨA\s?VIỆT\s?NAM\b".

Giải thích biểu thức:

- **(?i):** Đây là một cú pháp đặc biệt để bật chế độ không phân biệt chữ hoa chữ thường trong biểu thức chính quy.
- **\b:** Đây là một ký tự đặc biệt trong biểu thức chính quy để đánh dấu ranh giới từ (word boundary), đảm bảo rằng chỉ tìm kiếm các từ đầy đủ.
- **CỘNG\s?H[ÒO][ÃA]:** Tìm kiếm từ "CỘNG HÒA" hoặc "CỘNG HỒA" hoặc "CỘNG HÒA" (phân biệt chữ hoa chữ thường và có thể có khoảng trắng tùy chọn).
- **\s?X[ÃA]:** Tìm kiếm "XÃ" hoặc "XA" (có thể có khoảng trắng tùy chọn).
- **\s?HỘI\s?CHỦ\s?NGHĨA\s?VIỆT\s?NAM:** Tìm kiếm "HỘI CHỦ NGHĨA VIỆT NAM" (có thể có khoảng trắng tùy chọn).

✓ **Biểu thức chính quy 2:**

"(?i)\bĐộc\s?lập\s?- \s?Tự\s?do\s?- \s?Hạnh\s?phúc\b".

Giải thích biểu thức:

- **(?i):** Cũng là cú pháp để bật chế độ không phân biệt chữ hoa chữ thường.
- **\b:** Ký tự đặc biệt đánh dấu ranh giới từ.
- **Độc\s?lập:** Tìm kiếm "Độc lập" (có thể có khoảng trắng tùy chọn)
- **- \s?Tự\s?do:** Tìm kiếm "-" và "Tự do" (có thể có khoảng trắng tùy chọn).
- **- \s?Hạnh\s?phúc:** Tìm kiếm "-" và "Hạnh phúc" (có thể có khoảng trắng tùy chọn).

Bước 2: sau khi thiết kế xong 2 biểu thức chính quy, sử dụng thư viện “re” (regular expression) được cung cấp sẵn để làm việc với biểu thức chính quy. Trong trường hợp này dùng để tìm kiếm chuỗi thoả mãn biểu thức chính quy đã thiết kế ở trên.

- Trích xuất loại văn bản:

Bước 1:

Tạo một mảng các kí tự viết tắt của các loại văn bản: ["NQ", "QĐ", "CT", "QC", "QyĐ", "TC", "TB", "HD", "CTr", "KH", "PA", "ĐA", "DA", "BC", "BB", "TTr", "HĐ", "CĐ", "BGN", "BTT", "GUQ", "GM", "GGT", "GNP", "PG", "PC", "PB"]. Mảng này dùng để tìm kiếm trong đoạn text đã được lấy ra bằng Pytesseract OCR.

Tạo một mảng các chữ đầy đủ của các kí tự viết tắt trên: ["Nghị quyết", "Quyết định", "Chỉ thị", "Quy Chế", "Quy định", "Thông cáo", "Thông báo", "Hướng dẫn", "Chương trình", "Kế hoạch", "Phương án", "Đề án", "Dự án", "Báo cáo", "Biên bản", "Tờ trình", "Hợp đồng", "Công điện", "Bản ghi nhớ", "Bản thỏa thuận", "Giấy ủy quyền", "Giấy mời", "Giấy giới thiệu", "Giấy nghỉ phép", "Phiếu gửi", "Phiếu chuyển", "Phiếu báo"]. Mảng này dùng để hiển thị tên đầy đủ của loại văn bản.

Bước 2: Sử dụng vòng lặp enumerate lặp qua mảng các kí tự viết tắt nếu xuất hiện trong đoạn text sẽ trả về vị trí tương ứng tên đầy đủ của kí tự viết tắt và đó cũng là tên đầy đủ của loại văn bản cần trích xuất.

- Trích xuất số văn bản:

Bước 1: xây dựng biểu thức chính quy tìm số văn bản: "Số:\s+(\S+)(?=\s)".

Giải thích biểu thức:

- "Số:": Đây là một chuỗi ký tự cụ thể, trong trường hợp này là "Số:".
- \s+: Đây là một ký tự đặc biệt trong biểu thức chính quy, đại diện cho một hoặc nhiều khoảng trắng.
- (\S+): Đây là một nhóm chụp (capturing group) được đặt trong dấu ngoặc đơn, được đại diện bằng \S+. \S đại diện cho bất kỳ ký tự không phải khoảng trắng nào và + đại diện cho một hoặc nhiều lần xuất hiện.
- (?=\s): Đây là một lookahead assertion, được đại diện bởi (?=). Nó kiểm tra xem sau nhóm chụp, có một khoảng trắng (dấu cách) tiếp theo hay không, mà không đưa vào kết quả.

Bước 2: sau khi thiết kế xong 2 biểu thức chính quy, sử dụng thư viện "re" (regular expression) được cung cấp sẵn để làm việc với biểu thức chính quy. Trong trường hợp này dùng để tìm kiếm chuỗi thoả mãn biểu thức chính quy đã thiết kế ở trên.

- Trích xuất nội dung văn bản:

Bước 1: xây dựng biểu thức chính quy lấy nội dung của văn bản:

"(?:V/v|v/v|Về việc|Về Việc)(.*?)(?:\n|\$)".

Giải thích biểu thức:

- (?:V/v|v/v|Về việc|Về Việc): Tiềm các chuỗi V/v, v/v, Về việc, Về việc.
- (.*)?: Đây là một capturing group được đặt trong dấu ngoặc đơn. .*? đại diện cho bất kỳ chuỗi ký tự nào (bao gồm cả khoảng trắng) và ? là một quantifier để tìm kiếm một hoặc nhiều lần xuất hiện của capturing

group này một cách không tham lam (non-greedy). Kết quả sẽ là chuỗi ký tự được tìm thấy giữa phân tử bắt đầu và phân tử kết thúc.

- **(?:\n|\$)**: Đây là một non-capturing group khác, giống như non-capturing group đầu tiên. Nó tìm kiếm một trong hai trường hợp sau:

\n: Tìm kiếm một ký tự xuống dòng.

\$: Tìm kiếm kết thúc của chuỗi (end of string).

Bước 2: sau khi thiết kế xong 2 biểu thức chính quy, sử dụng thư viện “re” (regular expression) được cung cấp sẵn để làm việc với biểu thức chính quy. Trong trường hợp này dùng để tìm kiếm chuỗi thoãn mãn biểu thức chính quy đã thiết kế ở trên.

- Trích xuất ngày ban hành:

Bước 1: xây dựng biểu thức chính quy

"ngày\s+(\d{1,2})\s*(?:tháng)\s*(\d{1,2})\s*(?:năm)\s*(\d{4})"

Giải thích biểu thức:

- **ngày**: Đây là một chuỗi ký tự cụ thể, trong trường hợp này là "ngày".
- **\s+**: Đây là một ký tự đặc biệt trong biểu thức chính quy, đại diện cho một hoặc nhiều khoảng trắng.
- **(\d{1,2})**: Đây là một capturing group được đặt trong dấu ngoặc đơn. \d{1,2} đại diện cho một hoặc hai chữ số, trong trường hợp này là ngày.
- **\s***: Đây là một ký tự đặc biệt trong biểu thức chính quy, đại diện cho không hoặc một hoặc nhiều khoảng trắng.
- **(?:tháng)**: Đây là một non-capturing group, tìm kiếm chuỗi "tháng" trong văn bản, nhưng không trích xuất vào kết quả.
- **\s***: Đây là một ký tự đặc biệt trong biểu thức chính quy, đại diện cho không hoặc một hoặc nhiều khoảng trắng.
- **(?:năm)**: Đây là một non-capturing group, tìm kiếm chuỗi "năm" trong văn bản, nhưng không trích xuất vào kết quả.
- **(\d{4})**: Đây là một capturing group khác, đại diện cho bốn chữ số, trong trường hợp này là năm.

Bước 2: : sau khi thiết kế xong 2 biểu thức chính quy, sử dụng thư viện “re” (regular expression) được cung cấp sẵn để làm việc với biểu thức chính quy. Trong trường hợp này dùng để tìm kiếm chuỗi thoãn mãn biểu thức chính quy đã thiết kế ở trên.

3.2.2 Thiết kế API cho ứng dụng


Trước khi viết API cho ứng dụng, cần phải thiết kế nơi lưu trữ cơ sở dữ liệu người dùng. Trong ứng dụng này sử dụng pymongo để thiết kế lưu trữ dữ liệu.

Thiết kế dữ liệu cho ứng dụng

Bước 1: xây dựng một OCR_MODELS bằng thư viện pydantic bao gồm các thuộc tính cần lưu trữ như: qhtn (quốc hiệu tiêu ngữ), loaivanban (loại văn bản), ngayviet (ngày ban hành), so (số văn bản), noidung (nội dung văn bản).


Bước 2: sử dụng pymongo và các hàm được cung cấp bởi pymongo như (insert_one, update_one, delete_one, find) để viết các hàm như: tạo dữ liệu, lấy tất cả dữ liệu, xóa dữ liệu, sửa dữ liệu.

Thiết kế API upload file pdf văn bản hành chính và kiểm tra kết quả




Hình 1: Kết quả kiểm tra hoạt động của API POST

Thiết kế API hiển thị tất cả thông tin file pdf và kiểm tra kết quả



Hình 2: Kết quả kiểm tra hoạt động của API GET


Thiết kế API xóa dữ liệu đã trích xuất và kiểm tra kết quả



Hình 3: Kết quả kiểm tra hoạt động của API DELETE


Thiết kế API chỉnh sửa dữ liệu đã trích xuất và kiểm tra kết quả

Dữ liệu ban đầu khi dữ chỉnh sửa:



Hình 4: Dữ liệu trước khi chỉnh sửa

Dữ liệu sau khi chỉnh sửa:




Hình 5: Kết quả kiểm tra hoạt động của API PUT

3.2.2 Thiết kế giao diện cho ứng dụng

Phần giao diện của ứng dụng được sử dụng ReactJS để thiết kế, và các thư viện khác như axios để đọc API từ server, bootstrap để thiết kế giao diện đơn giản.

Giao diện trang chủ:

■ OCR




Số	
Ngày viết	
Loại văn bản	
Quốc hiệu tiêu ngữ	
Nội dung	
Cập nhật thông tin	<button>Cập nhật</button>

Ghi chú: Nếu thông tin chưa đúng hoặc còn để trống hãy ấn vào nút "Cập nhật" để chỉnh sửa và bổ sung thông tin.

Hình 6: Trang chủ

Giao diện trang cập nhật:

Cập nhật thông tin



Số	
Loại văn bản	
Ngày viết	
Quốc hiệu tiêu ngữ	
Nội dung	

SaveList

Hình 7: Trang cập nhật thông tin

Trang danh sách các văn bản được trích xuất:

Danh sách các văn bản

Số	2822/QĐ-ĐKC
Ngày viết	Ngày 11 Tháng 11 Năm 2020
Loại văn bản	Quyết định
Quốc hiệu tiêu ngữ	CỘNG HÒA XÃ HỘI CHỦ NGHĨA VIỆT NAM Độc lập - Tự do - Hạnh phúc
Nội dung	tặng học bổng "Hỗ trợ sinh viên vùng lũ"

Số	QD1B/951
Ngày viết	Ngày 24 Tháng 10 Năm 2022
Loại văn bản	Quyết định
Quốc hiệu tiêu ngữ	Cộng Hòa Xã Hội Chủ Nghĩa Việt Nam Độc lập - Tự do - Hạnh phúc
Nội dung	Hỗ trợ sinh viên nghèo

[Previous](#) [1](#) [Next](#)

Hình 8: Trang danh sách các văn bản

OCR

Drop files here

or

Choose File 0001(280).pdf

Số	2822/QĐ-ĐKC
Ngày viết	Ngày 11 Tháng 11 Năm 2020
Loại văn bản	Quyết định
Quốc hiệu tiêu ngữ	CỘNG HÒA XÃ HỘI CHỦ NGHĨA VIỆT NAM Độc lập - Tự do - Hạnh phúc
Nội dung	tặng học bổng "Hỗ trợ sinh viên vùng lũ"
Cập nhật thông tin	Cập nhật

Ghi chú: Nếu thông tin chưa đúng hoặc còn để trống hãy ấn vào nút "Cập nhật" để chỉnh sửa và bổ sung thông tin.

Hình 9: Kiểm tra hoạt động trích xuất thông tin

Phần 4

KẾT QUẢ ĐẠT ĐƯỢC QUA ĐỢT THỰC TẬP

4.1 Những kết quả đạt được

Tuy thời gian thực tập tại Trung tâm công nghệ phần mềm VNPT Vĩnh Long không được nhiều nhưng cũng để lại cho em những kiến thức bổ ích và những kinh nghiệm thực tế sẽ giúp ích cho công việc của em sau này được tốt hơn. Em được những kiến thức và kinh nghiệm là được sự giúp đỡ tận tình của anh Phan Thanh Giảng các cán bộ ở trung tâm trong suốt quá trình thực tập đã giúp đỡ và cho em học hỏi được rất nhiều điều. Những kỹ năng làm việc và báo cáo của em cũng được tiến bộ nhờ tiếp thu từ các anh hướng dẫn.

4.2 Bài học kinh nghiệm và những điều đạt được sau 8 tuần thực tập

Theo em để làm tốt một công việc cụ thể là làm tốt công việc liên quan đến công nghệ thông tin, điều cần thiết không chỉ là các kiến thức lý thuyết mà còn cần có những kinh nghiệm thực tế được đúc kết trong quá trình học tập và làm việc.

Một trong những kinh nghiệm quan trọng là kỹ năng mềm, kỹ năng giao tiếp, kỹ năng ứng xử của bản thân đối với mọi người xung quanh và thái độ lúc chúng ta làm việc khi được giao phó. Bên cạnh đó kỹ năng làm việc nhóm giúp chúng ta làm việc hiệu quả và năng suất cao hơn. Học hỏi mọi người xung quanh để đúc kết được kinh nghiệm cho bản thân mình. Đọc hiểu tài liệu cũng giúp ích rất nhiều trong quá trình mình làm việc.

Trong quá trình thực tập, em đã có cơ hội làm quen với một môi trường làm việc mới.

Tích lũy được những kinh nghiệm về kiến thức, kinh nghiệm về kỹ năng giao tiếp cũng như ứng xử với mọi người trong quanh và trong công việc.

Rèn luyện được khả năng giải quyết công việc theo từng giai đoạn, cố gắng hoàn thành công việc trong khoản thời gian định trước, mạnh dạn học hỏi trao đổi kiến thức.

Đồng thời bồi dưỡng thêm rất nhiều kiến thức ngoài các kiến thức được học ở trường lớp.

4.3 Hướng phát triển

Hiện tại ứng dụng còn một số hạn chế ở phần trích xuất nếu như giai đoạn nhận diện các chữ viết trong văn bản bị sai chính tả hoặc có chữ viết tay. Trong tương lai sẽ cố gắng khắc phục lỗi này và xây dựng mô hình mạnh mẽ hơn có thể nhận biết cả chữ viết tay thay vì chỉ là chữ đánh máy.

Về phần giao diện hiện tại chỉ xây dựng một giao diện đơn giản, trong tương lai sẽ xây dựng thêm giao diện bắt mắt hơn, thêm nhiều chức năng cho ứng dụng hơn nữa.